Sistemi Operativi

Laurea in Ingegneria Informatica Università di Roma Tor Vergata Docente: Francesco Quaglia



Virtual file system

- 1. Nozioni preliminari
- 2. Architettura di base e funzioni
- 3. Gestione dei file
- 4. Utenze e gruppi
- 5. Gestione dei dispositivi fisici
- 6. Virtual file system in sistemi operativi attuali (UNIX/Windows)

Virtual file system – concetti basici

- È costituito da tutti i moduli di livello kernel che supportano operazioni di I/O
- Queste avvengono <u>secondo uno schema omogeneo</u> (stesse system call) indipendentemente da quale sia l'oggetto di I/O coinvolto nell'operazione
- Si basano quindi su modelli di riferimento quali:
 - ✓ stream I/O
 - ✓ block I/O
- System call ad-hoc esistono quindi solo in relazione all'<u>istansiazione dei vari oggetti di I/O</u> (non alle vere e proprie operazioni su di essi)

Overview

Istansiazione/eliminazione di oggetti di I/O (interfacce specifiche per tipologie di oggetti)


Files
Pipes
FIFOs
Mailslots
Sockets
Char devices
Block devices

UNIX and/or Windows

Reali operazioni di I/O (interfaccia comune)

Letture
Scritture
Ripozionamenti
Eliminazione di contenuti (se non volatili)

Stream/block I/O model



scritte in precedenza

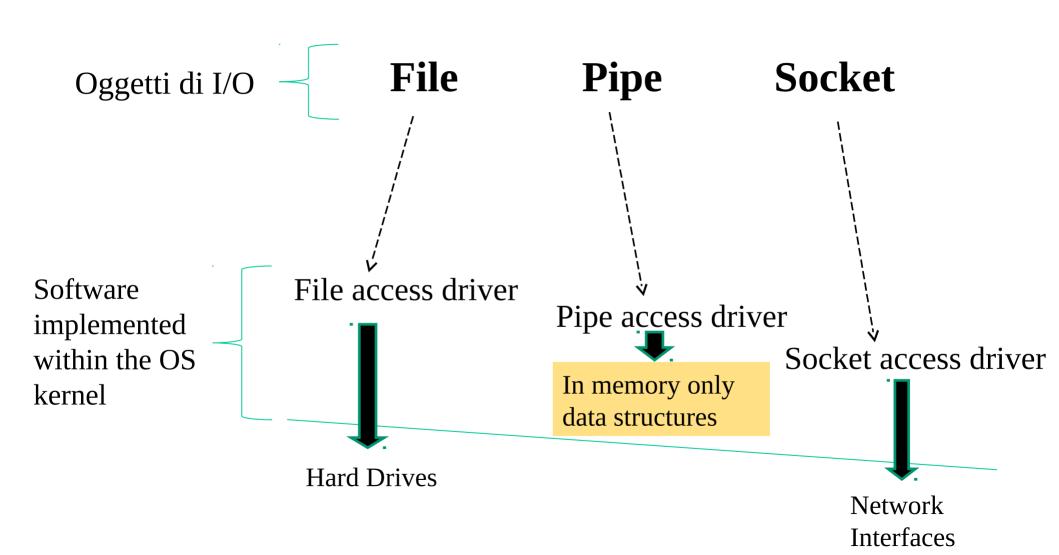
✓ hard disks

network interfaces

Drivers


- Tipi di oggetti di I/O differenti sono generalmente rappresentati tramite strutture dati differenti
- Inoltre non tutti i tipi di oggetti di I/O hanno una rappresentazione di backend (volatile o non) su dispositivi hardware
- Inoltre le eventuali rappresentazioni di backend possono afferire a dispositivi hardware differenti
- Tutta questa eterogeneità è risolta in modo del tutto trasparente al codice applicativo tramite il concetto di driver
- <u>Il driver è l'insieme di moduli software di livello kernel per eseguire le operazioni afferenti ad un qualsiasi oggetto di I/O</u>
- Ogni tipologia di oggetti ha la sua tipologia di driver

Uno schema




Canali di I/O

- Sono identificatori logici per eseguire operazioni di I/O sugli oggetti
- Ovvero chiavi di accesso all'istanza di oggetto di I/O
- Il setup del canale di I/O richiede istansiazione e/o apertura dell'oggetto
- I canali di I/O portano il kernel a riconoscere l'istanza di oggetto target tramite la tabella degli oggetti accessibili al processo



Sessioni di I/O

- Il setup del canale di I/O porta automaticamente al setup della cosí detta sessione di lavoro (sessione di I/O) sull'oggetto target
- Questa mantiene dati temporanei relativi alle operazioni che vengono eseguite sul canale di I/O



I/O e archiviazione - il file system

Il punto di vista del sistema operativo

- minima unità informativa archiviabile: il file
- informazioni in archivio (ovvero su dispositivi di memoria di massa), potranno essere contenute esclusivamente all'interno di un file

Il punto di vista delle applicazioni

• minima unità informativa accessibile (manipolabile): il record




Il file system mostra alle applicazioni ogni singolo file come una semplice <u>sequenza</u> di records

Un file system associa ad ogni file un insieme di attributi

- Nome (identificazione univoca)
- Protezione (controllo sugli accessi)
- Altro, e.g. timestamp, bounds (dipendendo dallo specifico sistema)

Architettura di base di un file system



Operazioni base sui file

Creazione

• allocazione di un "record di sistema" (RS) per il mantenimento di informazioni relative al file (e.g. attributi) durante il suo tempo di vita

Scrittura/Lettura (di record)

• aggiornamento di un indice (puntatore) di scrittura/lettura valido per sessione

Apertura (su file esistenti)

• inizializzazione dell'indice di scrittura/lettura per la sessione corrente

Chiusura

• rilascio dell'indice di scrittura/lettura

Riposizionamento

• aggiornameno dell'indice di scrittura/lettura

Eliminazione

• deallocazione di RS e rilascio di memoria (blocchi dati) sul dispositivo


Troncamento

• rilascio di memoria (blocchi dati) sul dispositivo

Indici di scrittura/lettura

• L'indice di scrittura/lettura **NON** fa parte di RS (accessi concorrenti su punti del file scorrelati)


• L'indice di scrittura/lettura **PUÒ** essere condiviso da più processi



• Le <u>modalità di aggiornamento</u> dell'indice di scrittura/lettura **in riposizionamento** dipendono dai <u>metodi di accesso</u> ai record di un file supportati dallo specifico file system

Metodo di accesso sequenziale

- i records vengono acceduti sequenzialmente
- l'indice di scrittura/lettura è incrementato di una unità per ogni record acceduto
- il riposizionamento dell'indice può avvenire solo all'inizio del file




Tipico di:

- File sequenziali, caratterizzati da record di taglia e struttura fissa
- <u>File a mucchio</u>, caratterizzati da record di taglia e struttura variabile (ogni record mantiene informazioni esplicite su taglia e struttura)

Metodo di accesso sequenziale indicizzato

Tipico di:

• <u>File sequenziali indicizzati</u>, caratterizzati da record di taglia e struttura fissa, ordinati in base ad un campo chiave




- esiste un file sequenziale di indici associato a ciascun file di dati
- i record sono ordinati per "chiave"
- tramite il file di indici ci si può posizionare in punti specifici del file di dati (ovvero in punti con valori specifici del campo chiave)
- i records vengono acceduti sequenzialmente una volta posizionati sui punti stabiliti
- l'indice di scrittura/lettura è manipolato (incrementato) di conseguenza
- il riposizionamento dell'indice può avvenire solo all'inizio del file

Metodo di accesso diretto

- il riposizionamento dell'indice può avvenire in un qualsiasi punto del file
- si può accedere direttamente all'i-esimo record (senza necessariamente accedere ai precedenti)
- dopo un accesso all'iesimo record, l'indice di scrittura/lettura assume il valore i+1

Tipico di:

- File diretti, caratterizzati da record di taglia e struttura fissa
- **File hash**, caratterizzati da record di taglia e struttura fissa con ordinamento per chiave



Struttura di directory

- La directory è un file ``speciale``
- Essa contiene informazioni per poter accedere a file veri e propri, contenenti record di dati
- Il modo con cui le informazioni vengono mantenute nelle directory (ovvero nei file associati alle directory) determinano la cosí detta **struttura di directory**

Tipica struttura di directory

- nomi dei file contenuti nella directory
- informazioni di identificazione dei RS associati ai file



File vs blocchi di dispositivo (i)

- Ciascun file è allocato sul dispositivo di memoria di massa come un insieme di blocchi (chiamati anche blocchi logici) non necessariamente contigui
 - 1. <u>organizzazione fissa</u>: record di taglia fissa possibilità di frammentazione interna
 - 2. organizzazione variabile con riporto: record di taglia variabile con possibilità che un record sia suddiviso tra più blocchi
 - 3. organizzazione variabile senza riporto: come 2) ma con possibilità di frammentazione interna

File vs blocchi di dispositivo (ii)

- Le unità di allocazione possono essere costituite da più blocchi (per motivi di efficienza)
- RS tiene traccia di quanti e quali blocchi sono allocati per un dato file
- Il file system tiene conto degli spazi liberi sul dispositivo di memoria di massa tramite apposite strutture:
 - **A)** *Lista Libera*: tiene traccia di unità di allocazione libere
 - **B)** *Bit Map*: dedica un bit ad ogni unità di allocazione, per indicare se essa è libera o meno

Lista libera e bit-map – esempi per Hard Disks

Track	Sector	Number of sectors in hole		
0 1 1 2 2 2 3 4	0 6 0 11 1 3 7 0 9 3	5 6 10 1 1 3 5 3 3 8		
(a)				


						Sec	ctor					
Track	0	1	2	3	4	5	6	7	8	9	10	11
0	0	0	0	0	0	1	0	0	0	0	0	0
1	0	0	0	0	0	0	0	0	0	0	1	0
2 3	1	0	1	0	0	0	1	0	0	0	0	0
3	0	0	0	1	1	1	1	1	1	0	0	0
4	1	1	1	0	0	0	0	0	0	0	0	1
(b)												

(a)

- (a) Lista Libera
- (b) Bit Map


Allocazione di file contigua

- un insieme di blocchi contigui è allocato per un file all'atto della creazione
- la taglia massima dipende dal numero di blocchi allocati
- l'occupazione reale è sempre pari al numero di blocchi allocati (anche se essi non contegono record del file)
- RS mantiene informazioni sul primo blocco e sul numero di blocchi
- ricompattazione per affrontare il problema della <u>frammentazione esterna</u>




Allocazione di file a catena

- i blocchi di un file sono collegati come in una lista
- l'occupazione reale e' sempre pari al numero di blocchi realmente nella lista
- RS mantiene informazioni sul primo blocco
- accesso potenzialmente costoso
- ricompattazione utile per diminuire il costo di accesso




Allocazione di file indicizzata

- i blocchi di un file sono rintracciati tramite un indice
- l'occupazione reale è sempre pari al numero di blocchi realmente allocati per record del file
- RS mantiene informazioni sugli indici dei blocchi (maggiore occupazione di spazio per RS rispetto ad altri schemi)



Indicizzazione a livelli multipli



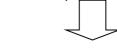
Indici di blocchi di dati possono anche <u>non essere presenti</u> in RS

Cache dei dispositivi

- il sistema operativo mantiene una regione di memoria che funge da buffer temporaneo (**buffer cache**) per i dati acceduti in I/O **e che siano riaccessibili**
- hit nel buffer cache evita interazione con gli hard-drive (diminuzione della <u>latenza</u> e del <u>carico sugli hard-drive</u>)
- efficienza legata alla <u>località</u> delle applicazioni (<u>lettura anticipata/ scrittura</u> <u>ritardata</u>)

Strategia di sostituzione dei blocchi


- Least-Recently-Used: viene mantenuta una lista di gestione a stack
- Least-Frequently-Used: si mantiene un contatore di riferimenti al blocco indicante <u>il numero di accessi</u> da quando è stato caricato



Problemi sulla <u>variazione di località</u>


Buffer cache a due sezioni

- ogni volta che un blocco è riferito, il suo contatore di riferimenti <u>è incrementato</u> ed il blocco è portato nella <u>sezione nuova</u>
- per i blocchi nella sezione nuova il contatore di riferimenti <u>non viene incrementato</u>
- per la sostituzione dalla sezione nuova si sceglie il blocco con il <u>numero di</u> <u>riferimenti minore</u>
- la stessa politica è usata per la sostituzione nella **sezione vecchia**



Buffer cache a tre sezioni

- esiste una <u>sezione intermedia</u>
- i blocchi della sezione intermedia vengono passati nella sezione vecchia <u>per effetto</u> della politica di sostituzione
- un blocco della sezione nuova difficilmente verrà escluso dal buffer cache in caso sia riferito in breve tempo dall'uscita dalla sezione nuova



I/O e swapping

Collocamento dell'area di swap

- file system
 - 1. <u>Funzioni di gestione del file system</u> vengono usate anche per l'area di swap
 - 2. Possibilità di gestione inefficiente (tradeoff spazio-tempo)
 - 3. Taglia dell'area non predefinita
- partizione privata
 - 1. Esiste un gestore dell'area di swap
 - 2. La disposizione sul dispositivo può essere tale da ottimizzare l'accesso in termini di velocità
 - 2. Ammessa la possibilità di <u>elevata frammentazione interna</u>
 - 3. Taglia dell'area predefinita

UNIX file systems

- Berkeley Fast File System also known as UFS (Unix File System)
- Ext2
- Ext3
- Ext4
- Btrfs (Better File System)
- **XFS**
- JFS (Journal FS)



LINUX (ever larger files + journaling + de-duplication + ACL + other)

IRIX/LINUX

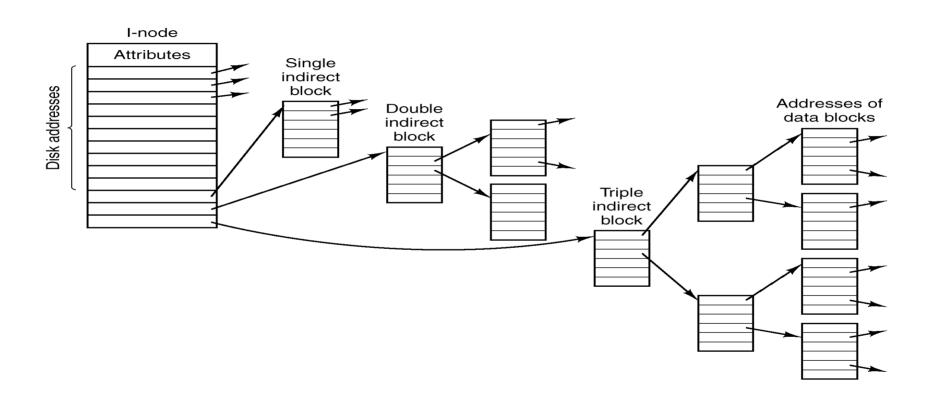


AIX (IBM)

Caratteristiche di base dei file system UNIX

- Ogni file è trattato dal file system come una semplice sequenza di bytes (stream)
- Metodo di accesso diretto
- L'RS viene denominato **i-node**
- Esiste un vettore di i-nodes di dimensione fissata
- Organizzazione gerarchica dell'archivio
 - 1) la directory associa ad ogni file il numero di i-node corrispondente
 - 2) struttura di directory-entry: numero di i-node spiazzamento per la entry
 - successiva lunghezza del nome nome
- Bit map per blocchi dati e per i-nodes

Classica struttura di un i-node



Taglia massima di un file - un esempio

Parametri (dipendenti dalla versione di file system ed hard drive)


- Blocchi su disco da 512 byte
- Indirizzi su disco 4 byte
- In un blocco: 512/4 = 128 indirizzi
 - ind. 1-10 10 blocchi dati
 - ind. 11128 blocchi dati
 - ind. 12
 128² blocchi dati
 - ind. 13
 128³ blocchi dati

Maxfile =
$$10+128 + 128^2 + 128^3 =$$

2.113.664 blocchi * 512 bytes =
 $1.082.195.968 \approx 1$ Gbyte.

Ext4 - extents

- le extents sono un modo per indicizzare <u>blocchi multipli contigui (nel file e su dispositivo) con un unica struttura indice</u> la taglia attuale è fino a 128 MB
- sono un modo per poter cambiare la natura di una struttura indice di blocco di dispositivo qualora sia utile
- un i-node ha quindi una serie di indici che possono essere
 - Diretti a sequenze di blocchi dati (ultimo livello) questa è una extent
 - Indiretti a blocchi di indici (livelli superiori)
- La struttura di fatto diventa un albero



Le extent possono essere in un i-node o in un blocco intermedio indicizzato

Attributi basici

{-,d,b,c,p}	tipologia di file: normale, directory, block-device, character-device, pipe
UID (2/4 byte) GID (2/4 byte)	<u>identificatori</u> del proprietario e del suo gruppo
rwx rwx	permessi di accesso per proprietario, gruppo, altri (codifica ottale)
SUID (1 bit) SGID (1 bit)	specifica di identificazione dinamica per chi utilizza il file
Sticky (1 bit)	<u>per le directory</u> rimuove la possibilità di cancellare files se non si è l'owner

Associazione userid-username

- Questa associazione non è una specifica presente nei metadati di gestione dei file a livello del file system
- Essa è solo una sovrastruttura utilizzata per comodità
- Tale associazione viene quindi realizzata tramite informazioni di mapping che associano userid e username, le quali vengono mantenute all'interno di specifici file
- Uno di questi è il file delle utenze /etc/passwd
- La stessa cosa è vera per l'identificativo del gruppo ed il nome del gruppo (si veda il file /etc/group)

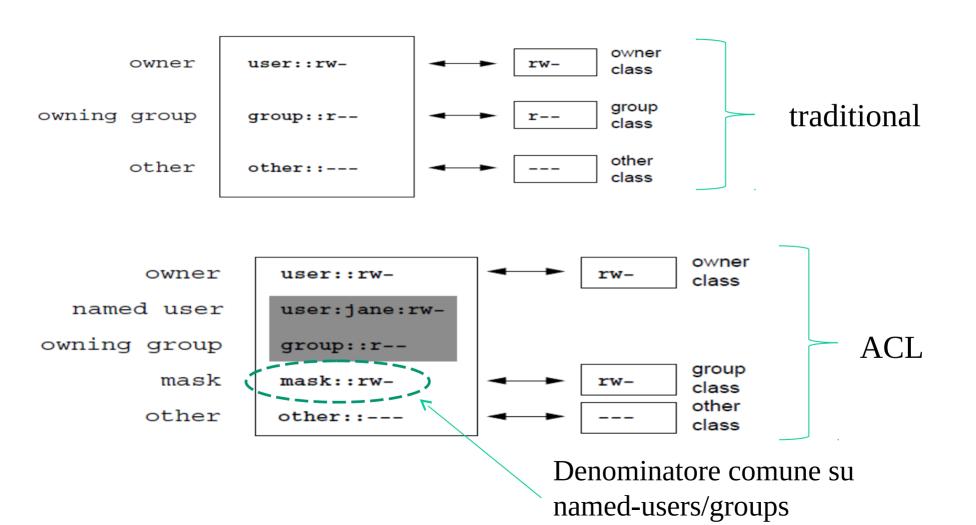
User-id/group-id e processi

- Ad ogni processo viene associato un insieme di identificatori numerici
- Questi identificatori sono relativi ad utenze e gruppi
- Questi identificatori vengono controllati quando si cerca di accedere a file o lanciare programmi tramite incrocio con i permessi di accesso
- Servizi base di gestione degli identificatori utente:


ACL (Access Control List)

- Permette di avere i-nodes in cui specifichiamo a grana molto piú fine i permessi di accesso e gestione dei file
- Una ACL è realizzata ramite un <u>file shadow</u> (associato al file originale)
- Quindi anche tramite un **i-node shadow**
- L'i-node originale in tal caso ha un indice che identifica l'i-node shadow
- Con ACL si può per ogni file specificare i permessi di accesso per ogni singolo utente o gruppo del sistema
- I comandi basici di shell per gestire ACL sono **getfacl** e **setfacl**

ACL example




UNIX virtual file system (I)



UNIX virtual file system (II)

- i dispositivi vengono gestiti come file
- ogni i-node del file system virtuale viene associato o ad un file o ad un dispositivo
- le <u>funzioni realmente eseguite</u> su richiesta delle applicazioni dipendono dall'entità associata all'<u>i-node relativo al descrittore per il quale viene</u> <u>invocata la funzione</u>
- gli i-node associati ai file sono <u>riportati su hard-drive</u> allo spegnimento (shutdown) se non prima
- gli i-node associati ai dispositivi possono essere <u>rimossi allo spegnimento</u> (i-node dinamici)
- la cache degli i-node serve per gestire i-node dinamici e per rendere l'accesso ai file più efficiente
- esiste un **buffer-cache** per tenere temporaneamente i blocchi di dati relativi ai file in memoria di lavoro

Architettura di I/O in sistemi UNIX



Creazione di file

```
int creat(char *file_name, int mode)

Descrizione invoca la creazione un file

Argomenti 1) *file_name: puntatore alla stringa di caratteri che definisce il nome del file da creare

2) mode: specifica i permessi di accesso al file da creare (codifica ottale)

Restituzione -1 in caso di fallimento; un descrittore di file altrimenti
```

Esempio

```
void main() {
    if(creat("pippo",0666) == -1) {
        printf("Errore nella chiamata creat\n");
        exit(EXIT_FAILURE);
    }
}
```

Apertura/chiusura di file

int open(char *file_name, int option_flags [, int mode])

Descrizione invoca la creazione un file

Argomenti 1) *file_name: puntatore alla stringa di caratteri che definisce il nome del file da aprire

2) option_flags: specifica la modalita' di apertura (read, write etc.)

3) mode: specifica i permessi di accesso al file in caso di creazione contestuale

all'apertura

Restituzione -1 in caso di fallimento, altrimenti un descrittore per l'accesso al file

int close(int descriptor)

Descrizione invoca la chiusura di un file

Argomenti descriptor: descrittore del file da chiudere

Restituzione -1 in caso di fallimento

Valori per "option_flags"

- O_RDONLY: apertura del file in sola lettura;
- O_WRONLY: apertura del file in sola scrittura;
- O_RDWR: apertura in lettura e scrittura;
- O_APPEND: apertura del file con puntatore alla fine del file; ogni scrittura sul file sara' effettuata a partire dalla fine del file;
- O_CREAT : crea il file con modalità d'accesso specificate da *mode* sole se esso stesso non esiste;
- O_TRUNC : elimina il contenuto del file se esso è già esistente.
- O_EXCL : (exclusive) serve a garantire che il file sia stato effettivamente creato dalla chiamata corrente.
- definiti in fcnt1.h
- combinabili tramite l'operatore "|" (OR binario)

Operazioni di lettura/scrittura

```
ssize_t read(int descriptor, char *buffer, size_t size)
```

Descrizione invoca la lettura da un file

Argomenti 1) descriptor:descrittore relativo al file da cui leggere

- 2) buffer: puntatore al buffer dove memorizzare i byte letti
- 3) size: quantita' di byte da leggere

Restituzione -1 in caso di fallimento, altrimenti il numero di byte realmente letti

```
ssize_t write(int descriptor, char *buffer, size_t size)
```


Descrizione invoca la scrittura su un file

- **Argomenti** 1) descriptor:descrittore relativo al file su cui scrivere
 - 2) buffer: puntatore al buffer dove prendere i byte da scrivere
 - 3) size: quantita' di byte da scrivere

Restituzione -1 in caso di fallimento, altrimenti il numero di byte realmente scritti

Descrittori "speciali" ed eredità di descrittori

- 0 standard input
- 1 standard output
- 2 standard error



- associati a specifici oggetti di I/O ed utilizzati da molte funzioni di libreria standard (e.g. scanf()/printf())
- i relativi stream possono essere chiusi

Tutti i descrittori vengono ereditati <u>da un processo figlio</u> generato da una fork() sharing del file pointer

<u>Tutti i descrittori</u> (inclusi 0, 1 e 2) restano validi quando avviene una <u>sostituzione di codice</u> tramite una chiamata execX() eccetto che nel caso in cui si specifichi operatività close-on-exec (tramite la system-call fcntl() o il flag O_CLOEXEC in apertura del file)

Riposizionamento del file pointer

```
off_t lseek(int descriptor, off_t offset, int option)

Descrizione invoca il riposizionamento del file pointer

Argomenti 1) descriptor: descrittore relativo al file su cui riposizionarsi 2) offset: quantità di caratteri di cui spostare il file pointer 3) option: opzione di spostamento (da inizio, da posizione corrente, da fine – valori relativi: 0, 1, 2)

Restituzione -1 in caso di fallimento, altrimenti il nuovo valore del file pointer
```

Esempi

```
lseek(fd, 10, 0); /* Spostamento di 10 byte dall'inizio di fd */
lseek(fd, 20, 1); /* Spostamento di 20 byte in avanti dalla posizione corrente */
lseek(fd, -10, 1); /* Spostamento di 10 byte all'indietro dalla posizione corrente */
lseek(fd, -10, 2); /* Spostamento di 10 byte all'indietro dalla fine del file */
lseek(fd, -10, 0); /* Fallisce e il valore del file pointer resta uguale */
```

Duplicazione di descrittori e redirezione

```
int dup(int descriptor)

Descrizione invoca la duplicazione di un descrittore

Argomenti descriptor: descrittore da duplicare
```

Restituzione -1 in caso di fallimento, altrimenti un nuovo descrittore

Il descrittore restituito è il primo libero nella tabella dei descrittori del processo

Esempio

```
#include ...
#define FNAME "info.txt"
#define STDIN 0

int main() {
    int fd;
    fd = open(FNAME, O_RDONLY); /* Apro il file in lettura */
    close(STDIN); /* Chiudo lo standard input */
    dup(fd); /* Duplico il descrittore di file*/
    execlp("more", "more", 0); /* Eseguo 'more' con input redirezionato */
}
```

Più recenti standard

```
#include <unistd.h>
int dup(int oldfd)
int dup2(int oldfd, int newfd)
```

Specifica esplicita della posizione della "file-descriptor table" ove duplicare il canale originale

Controllo di canale di I/O

```
fcntl - manipulate file descriptor
SYNOPSIS
            top
       #include <unistd h>
       #include <fcntl.h>
       int fcntl(int fd, int cmd, ... /* arg */ );
DESCRIPTION
               top
       fcntl() performs one of the operations described below on the open
       file descriptor fd. The operation is determined by cmd.
       fcntl() can take an optional third argument. Whether or not this
       argument is required is determined by cmd. The required argument
       type is indicated in parentheses after each cmd name (in most cases,
       the required type is int, and we identify the argument using the name
       arg), or void is specified if the argument is not required.
```

NAME

top

Hard links e rimozione

int link(const char * oldpath, const char * newpath)

ritorna -1 in caso di fallimento

int unlink(const char *pathname)

ritorna -1 in caso di fallimento

Inseriscono/eliminano una directoryentry in un file speciale rappresentante una directory

Symbolic links

- Sono file il cui contenuto identifica una stringa che definisce parte o tutto un pathname
- Possono esistere indipendentemente dal target

```
SYNOPSIS
```

#include <unistd.h>

int symlink(const char *oldpath, const char *newpath)

Gestione delle directory

int mkdir(const char *pathname, mode_t mode)

int rmdir(const char *pathname)

Creazione/rimozione di directory

Gestione dei permessi d'accesso

NAME

chmod, fchmod - change permissions of a file

SYNOPSIS

```
#include <sys/types.h>
#include <sys/stat.h>

int chmod(const char *path, mode_t mode);
int fchmod(int fildes, mode_t mode);
```

DESCRIPTION

The mode of the file given by path or referenced by fields is changed.

varianti **chown** gestiscono il cambio di proprietà

Comandi shell basici per l'interazione con il File System

link makes hard links

ln makes symbolic links

dumpe2fs dump file system info

mkfs installs a file system on a device

stat list lower level file system information

Windows File System - NTFS

- Hard-drive divisi in volumi (partizioni), e organizzati in <u>cluster</u> da 512 a 64K byte
- per ogni volume si ha una **MFT** (**M**aster **F**ile **T**able)
- ad ogni file corrisponde <u>almeno</u> un elemento nella MFT
- l'elemento contiene:
 - nome del file: fino a 255 char Unicode
 - informazioni sulla sicurezza
 - nome DOS del file: 8+3 caratteri
 - i dati del file, o puntatori per il loro accesso <u>organizzazione stile extent</u>

MFT	file di sistema	area dei file


Bitmap dei cluster + logfile (recupero in caso di crash)

Alcuni attributi

Informazioni standard	attributi di accesso, timestamp	
Lista di attributi	dove localizzare nella MFT attributi che non entrano in un singolo record	
Descrittore di sicurezza	permessi di accesso per proprietario ed altri utenti	
Nome	identificazione nel sistema	
Dati	visti tipicamente come attributo o come indici per l'accesso	

MFT - Master File Table

- per piccoli file i dati sono direttamente nella parte dati nell'elemento della MFT (<u>file immediati</u>)
- per file grandi la parte dati dell'elemento della MFT contiene gli indirizzi di cluster o di gruppi di cluster consecutivi
- se un elemento della MFT non basta si aggregano altri



Architettura di I/O in sistemi Windows

Gestore di I/O

Driver del file system

Gestore della cache

Driver di dispositivi

- scrittura pigra: gli aggiornamenti vanno su hard-drive su base periodica
- sostituzione cache LRU
- swapping tramite thread di sistema (su file)

Creazione/apertura di file

HANDLE CreateFile(LPCTSTR lpFileName,

DWORD dwDesiredAccess,

DWORD dwShareMode,

LPSECURITY_ATTRIBUTES lpSecurityAttributes,

DWORD dwCreationDisposition,

DWORD dwFlagsAndAttributes,

HANDLE hTemplateFile)

Descrizione

• invoca la creazione di un file

Restituzione

• un handle al nuovo file in caso di successo

Parametri

- lpFileName: puntatore alla stringa di caratteri che definisce il nome del file da creare
- dwDesiredAccess: specifica i permessi di accesso al file da creare (GENERIC_READ, GENERIC_WRITE)
- dwShareMode: specifica se e quando il file può essere nuovamente aperto prima di essere stato chiuso (FILE_SHARE_READ, FILE_SHARE_WRITE)
- lpSecurityAttributes: specifica il descritore della sicurezza del file
- dwCreationDisposition: specifica l'azione da fare se il file esiste e quella da fare se il file non esiste (CREATE_NEW, CREATE_ALWAYS, OPEN_EXISTING, TRUNCATE_EXISTING)
- dwFlagsAndAttributes: specifica varie caratteristiche del file (FILE_ATTRIBUTES_NORMAL, ... HIDDEN, ... DELETE_ON_CLOSE)
- hTemplateFile: specifica un handle ad un file di template

Codifiche sui pathname

CreateFileA (...) ASCII

CreateFileW(...) UNICODE

Richiami su SECURITY_ATTRIBUTES

```
typedef struct _SECURITY_ATTRIBUTES {
    DWORD nLength;
    LPV0ID lpSecurityDescriptor;
    B00L bInheritHandle;
} SECURITY_ATTRIBUTES
Implementa la logica ACL
```

Descrizione

• struttura dati che specifica permessi

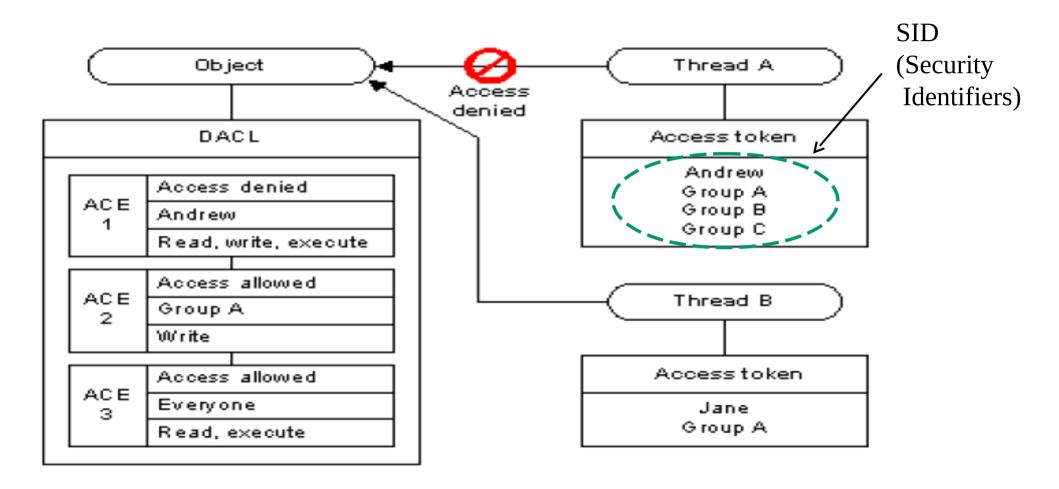
Campi

- nLength: va settato SEMPRE alla dimensione della struttura
- lpSecurityDescriptor: puntatore a una struttura SECURITY_DESCRIPTOR
- bInheritHandle: se uguale a TRUE un nuovo processo può ereditare l'handle a cui fa riferimento questa struttura

ACL (Access Control List)

- specifica la descrizione della sicurezza di oggetti, quindi anche di file
- è formata da una lista di ACE (Access Control Entry)
- nel caso di generazione di oggetti in cui il descrittore di sicurezza non è specificato, ACL viene popolata a partire dall'*access token* del processo chiamante
- in tal caso si ha una <u>ACL di default</u>
- ACL è formata da DACL (Discretionary ACL) e SACL (System ACL)
- DACL specifica i permessi
- SACL specifica azioni di log da eseguire in base agli accessi
- sono entrambe parti di un security descriptor

Un esempio



Struttura di un Security Identifier (SID)

- Esso contiene una parte iniziale che indica il formato del SID
- Poi viene specificata la "authority entity per il rilascio del SID"
- Poi viene specificato il dominio di rilascio del SID
- Poi viene specificato il codice relativo l'entità (user/group) relativa al SID
- Un esempio (in rappresentazione stringa):

S-1-5-domain-500 SID dell'utente Administrator



SECURITY_NT_AUTHORITY

Principali permessi gestibili da una ACE

- Modify
- Read & Execute
- Read
- Write

Tipici per file e cartelle

Schema di utilizzo - riepilogo

- Ogni processo ha dei Security IDentifier (come utente e come gruppo)
- I SID costituiscono l'access token che può direttamente garantire speciali privilegi (ad esempio l'accesso a qualsiasi file)
- Quando un processo cerca di accedere un oggetto viene utilizzato l'access token per controllare se il processo ha diritti incondizionati sull'oggetto
- Altrimenti il kernel "scandisce" l'ACL controllando le singole ACE
- La prima ACE che specificamente garantisce o nega l'accesso richiesto è decisiva nell'esito dell'accesso

Discovery dei SID

Tramite registry attraverso il file
 HKEY_LOCAL_MACHINE\SOFTWARE\Microsoft\WindowsNT\
 CurrentVersion\ProfileList

Tramite (power)shell command
 wmic useraccount get name, sid
 whoami /user

Manipolazione di ACL

GetNamedSecurityInfo
GetSecurityInfo
SetNamedSecurityInfo
SetSecurityInfo
SetSecurityInfo

A queste Win-API vengono associate una serie di ulteriori funzioni di libreria dello standard WinAPI per la manipolazione di security descriptors in user space

Un esempio

The **GetSecurityInfo** function retrieves a copy of the *security descriptor* for an object specified by a handle. **Syntax** C++ DWORD WINAPI GetSecurityInfo(In **HANDLE** handle, In_ SE OBJECT TYPE ObjectType, SECURITY INFORMATION SecurityInfo, In Out opt PSID *ppsidOwner, *ppsidGroup, Out opt PSID _Out_opt_ PACL *ppDacl, field pointers Out opt PACL *ppSacl, Out opt PSECURITY DESCRIPTOR *ppSecurityDescriptor into the descriptor); need <u>free</u> after usage

Tipi di oggetto

```
typedef enum SE OBJECT TYPE {
 SE UNKNOWN OBJECT TYPE
                             = 0,
 SE_FILE_OBJECT,
 SE SERVICE,
 SE PRINTER,
 SE REGISTRY KEY,
 SE LMSHARE,
 SE_KERNEL_OBJECT,
 SE WINDOW OBJECT,
 SE DS OBJECT,
 SE_DS_OBJECT_ALL,
 SE PROVIDER DEFINED OBJECT,
 SE_WMIGUID_OBJECT,
 SE REGISTRY WOW64 32KEY
} SE OBJECT TYPE;
```

Associazione SID/users/groups

LookupAccountSid function

The **LookupAccountSid** function accepts a *security identifier* (SID) as input. It retrieves the name of the account for this SID and the name of the first domain on which this SID is found.

Syntax

```
C++
  BOOL WINAPI LookupAccountSid(
   In opt LPCTSTR
                          lpSystemName,
                                                       actual buffers
    In
             PSID
                          lpSid,
                          lpName, <
    Out opt LPTSTR
                          cchName.
    Inout
             LPDWORD
   Out opt LPTSTR
                          lpReferencedDomainName,
                          cchReferencedDomainName,
    Inout
             LPDWORD
   _Out_
             PSID NAME USE peUse
  );
```

account type

buffer sizes

Costruzione di un security descriptor - schema

Servizi WinAPI da usare e sequenza di uso

- 1. InitializeSecurityDescriptor
- Reset della struttura dati

Scrittura dei SID nella

- 2. SetSecurityDescriptorOwner
- struttura dati

Inizializzazione di un buffer ACL

- 3. SetSecurityDescriptorGroup
- 4. InitializeAcl
- AddAccessDeniedAce....

Inserimento di ACE in ACL

- AddAccessAllowedAce... Collegamento di ACL al 7. SetSecurityDescriptorDacl security descriptor

Chiusura di file

BOOL CloseHandle(HANDLE hObject)



Descrizione

• invoca la chiusura di un oggetto (ad esempio un file)

Restituzione

• 0 in caso di fallimento

Lettura da file

BOOL ReadFile(HANDLE hFile,

LPVOID lpBuffer,

 $DWORD\ nNumber Of Bytes To Read,$

LPDWORD IpNumberOfBytesRead,

LPOVERLAPPED lpOverlapped)

Descrizione

• invoca la lettura di una certa quantità di byte da un file

Restituzione

• 0 in caso di fallimento

Parametri

- hFile: handle valido al file da cui si vuole leggere
- lpBuffer: puntatore all'area di memoria nella quale i caratteri letti devono essere bufferizzati
- tnNumberOfBytesToRead: definisce il numero di caratteri (byte) che si vogliono leggere
- lpNumberOfBytesRead: puntatore a un intero positivo corrispondente al numero di caratteri effettivamente letti in caso di successo
- lpOverlapped: puntatore a una struttura OVERLAPPED da usarsi per I/O asincrono

Scrittura su file

BOOL WriteFile(HANDLE hFile,

LPCVOID lpBuffer,

DWORD nNumberOfBytesToWrite,

 $LPDWORD\ IpNumber Of Bytes Written,$

LPOVERLAPPED lpOverlapped)

Descrizione

• invoca la scrittura di una certa quantita' di byte su un file

Restituzione

• 0 in caso di fallimento

Parametri

- hFile: handle valido al file su cui si vuole scrivere
- lpBuffer: puntatore all'area di memoria che contiene i caratteri da scrivere
- tnNumberOfBytesToWrite: definisce il numero di caratteri (byte) che si vogliono scrivere
- lpNumberOfBytesWritten: puntatore a un intero positivo corrispondente al numero di caratteri effettivamente scritti in caso di successo
- lpOverlapped: puntatore a una struttura OVERLAPPED da usarsi per I/O asincrono

Cancellazione di file

BOOL DeleteFile(LPCTSTR lpFileName)

Descrizione

• invoca la cancellazione di un file

Parametri

• lpFileName: puntatore alla stringa di caratteri che definisce il nome del file che si vuole rimuovere

Restituzione

• un valore diverso da zero in caso di successo, 0 in caso di fallimento

Riposizionamento del file pointer

DWORD SetFilePointer(HANDLE hFile,

LONG IDistanceToMove,
PLONG IpDistanceToMoveHigh,
DWORD dwMoveMethod)

Descrizione

• invoca il riposizionamento del file pointer

Restituzione

• INVALID_SET_FILE_POINTER in caso di fallimento, i 32 bit meno significativi del nuovo valore del file pointer (valutato in caratteri dall'inizio del file) in caso di successo

Parametri

- hFile: handle di file che identifica il canale di input/output associato al file per il quale si vuole modificare il file pointer
- 1DistanceToMove: i 32 bit meno significativi di un valore intero con segno indicante il numero di caratteri di cui viene spostato il file pointer
- lpDistanceToMoveHigh: (opzionale) puntatore a un long contenente i 32 bit piu' significativi del valore in lDistanceToMove
- dwMoveMethod: tipo di spostamento da effettuare (FILE_BEGIN, FILE_CURRENT, FILE_END)

Gestione degli standard handle

HANDLE WINAPI GetStdHandle(_In_ DWORD nStdHandle);

BOOL WINAPI SetStdHandle(_In_ DWORD nStdHandle, _In_ HANDLE hHandle);

Value	Meaning
STD_INPUT_HANDLE (DWORD)-10	The standard input device.
STD_OUTPUT_HANDLE (DWORD)-11	The standard output device.
STD_ERROR_HANDLE (DWORD)-12	The standard error device.

Gestione delle directory

```
BOOL WINAPI CreateDirectory(
    __in LPCTSTR lpPathName,
    __in_opt LPSECURITY_ATTRIBUTES lpSecurityAttributes);

BOOL WINAPI RemoveDirectory(
    __in LPCTSTR lpPathName);
```

NTFS hard links

BOOL WINAPI CreateHardLink(LPCTSTR lpFileName,

LPCTSTR lpExistingFileName,

LPSECURITY_ATTRIBUTES lpSecurityAttributes);

lpFileName [in]

- The name of the new file.
- This parameter cannot specify the name of a directory.

lpExistingFileName [in]

- The name of the existing file.
- This parameter cannot specify the name of a directory.

lpSecurityAttributes

Reserved; must be NULL.

NOTE (taken from MSDN online manual):

Because hard links are only directory entries for a file, many changes to that file are instantly visible to applications that access it through the hard links that reference it. However, the directory entry size and attribute information is updated only for the link through which the change was made.

The security descriptor belongs to the file to which a hard link points. The link itself is only a directory entry, and does not have a security descriptor. Therefore, when you change the security descriptor of a hard link, you change the security descriptor of the underlying file, and all hard links that point to the file allow the newly specified access. You cannot give a file different security descriptors on a per-hard-link basis.

NTFS symbolic links (.lnk shortcuts)

BOOLEAN WINAPI CreateSymbolicLink(
__in LPTSTR lpSymlinkFileName,
__in LPTSTR lpTargetFileName,
__in DWORD dwFlags)

lpSymlinkFileName [in]

The symbolic link to be created.

lpTargetFileName [in]

- The name of the target for the symbolic link to be created.
- If *lpTargetFileName* has a device name associated with it, the link is treated as an absolute link; otherwise, the link is treated as a relative link

dwFlags [in]


Indicates whether the link target, *lpTargetFileName*, is a directory.

See also the following prompt-command:

mklink

I/O scheduling

- Definisce la pianificazione tramite la quale <u>dispositivi di I/O</u> vengono realmente attivati per le loro operazioni
- In taluni casi I/O scheduling è semplicemente attuato secondo una politica FCFS
- Questo è <u>tipico dei terminali</u>, poichè utenti interattivi non sarebbero soddisfatti di osservare in output (o di fornire in input) dati fuori ordine (a causa di un riordino delle reali operazioni sul dispositivo)
- Ci sono però contesti in cui politiche più articolate di FCFS diventano fondamentali per l'efficienza dell'intera architettura di I/O, e quindi del virtual file system
- Questo è il caso degli hard-disk a rotazione, tutt'ora componenti centrali in architetture moderne



Dispositivi di memoria di massa

Dischi magnetici a rotazioni (Hard Disks)

- sono dispositivi elettro-meccanici
- sono tutt'ora i dispositivi con i migliori vantaggi in termini di capacità vs costo
- sono basati su tracce (che ospitano blocchi) e una testina che attraversa tracce per riposizionarsi
- ogni blocco corrisponde ad un "blocco logico" destinato per uno specifico file

Solid State Drives (SSD)

- sono dispositive elettronici della classe Non Volatile Memory (NVM)
- sono la tecnologia emergente, grazie alla più elevate velocità rispetto agli Hard Disks
- ogni blocco contiene un insieme di "blocchi logici" destinati ed ospitare file

Dischi magnetici a rotazione


- Ogni blocco è leggibile e scrivibile ad ogni istante di tempo
- Non ci sono fasi di vita di un blocco ove date operazioni (ad esempio una scrittura) non possono essere effettuate
- L'usura del dispositivo è essenzialmente legata all'usura delle parti meccaniche
- Non ci sono relazioni dirette tra le operazioni di lettura scrittura dei blocchi e l'usura (ovvero l'usura è primariamente legata al tempo di vita del dispositivo meccanico)
- Le relazioni sono indirette, dovute per esempio al fatto che per posizionare la testina su un blocco questa dovrà essere soggetta ad uno spostamento

Schedulazione dei dischi magnetici a rotazione

Parametri

- tempo di ricerca della traccia (seek time)
- <u>ritardo di rotazione</u> per l'accesso al settore sulla traccia

Punto di vista del processo



Valutazione dei parametri

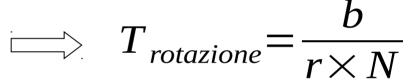
Seek time

- *n* = tracce da attraversare
- m = costante dipendente dal dispositivo \longrightarrow $T_{seek} = m \times n + s$
- s = tempo di avvio

Ritardo di rotazione

- b = bytes da trasferire
- N = numero di bytes per traccia
- r = velocità di rotazione (rev. per min.)

$\implies 1_{seek} = m \times n + s$



Valori classici

- s = 20/3/... msec.
- m = 0.3/0.1/.. msec.
- r = 300/3600/.../7200 rpm (floppy vs hard disk)

fattore critico

Scheduling FCFS (First Come First Served)

- le richieste di I/O vengono servite nell'ordine di arrivo
- non produce starvation
- non minimizza il seek time

Un esempio

Traccia iniziale =
$$100$$

Sequenza delle tracce accedute = $55 - 58 - 39 - 18 - 90 - 160 - 150 - 38 - 184$
distanze $45 - 3 - 19 - 21 - 72 - 70 - 10 - 112 - 146$


lunghezza media di ricerca

$$\frac{\sum_{i=1}^{|insiemedist|} dist_i}{|insiemedist|} = 55.$$

Scheduling SSTF (Shortest Service Time First)

insiemedist

- si dà priorità alla richiesta di I/O che produce il <u>minor movimento</u> <u>della testina</u>
- non minimizza il tempo di attesa medio
- può provocare <u>starvation</u>



Scheduling SCAN (elevator algorithm)

- il seek avviene in una <u>data direzione</u> fino al <u>termine delle tracce</u> o fino a che <u>non ci</u> sono più richieste in quella direzione
- sfavorevole all'area <u>attraversata più di recente</u> (ridotto sfruttamento della località)
- la versione C-SCAN utilizza <u>scansione in una sola direzione</u> (fairness nel servizio delle richieste)

50 - 10 - 24 - 94 - 32 - 3 - 16 - 1 - 20

Un esempio

Traccia iniziale = 100

Direzione iniziale = crescente

distanze

lunghezza media di ricerca


Insieme delle tracce coinvolte =
$$55 - 58 - 39 - 18 - 90 - 160 - 150 - 38 - 184$$

Riordino in base alla direzione di seek = $150 - 160 - 184 - 90 - 58 - 55 - 39 - 38 - 18$

rca
$$\frac{\sum_{i=1}^{|insiemedist|} dist_i}{\frac{i=1}{|insiemedist|}} = 27$$

Scheduling FSCAN (ad esempio LINUX)

- SSTF, SCAN e C-SCAN possono mantenere la testina bloccata in <u>situazioni patologiche</u> di accesso ad una data traccia
- FSCAN usa due code distinte per la gestione delle richieste
- la schedulazione avviene su una coda
- <u>l'immagazinamento delle richieste di I/O</u> per la prossima schedulazione avviene sull'altra coda
- nuove richieste <u>non vengono considerate</u> nella sequenza di scheduling già determinata



Dispositivi SSD

- Ogni blocco è leggibile e scrivibile
- Il blocco può essere scritto solo dopo esser stato "cancellato"
- Ad ogni cancellazione il blocco si "deteriora"
- Il numero massimo di cancellazioni prima che il blocco non sia più utilizzabile è dell'ordine di 100000 (detti anche cicli di cancellazione)
- C'è uno sbilanciamento nella velocità delle letture e delle scritture (dovuto alla cancellazione)
- Il controller del dispositivo SSD tipicamente implementa algoritmi di gestione trasparente del "derouting" delle scritture per ammortizzare costi ed effetti negativi della cancellazione

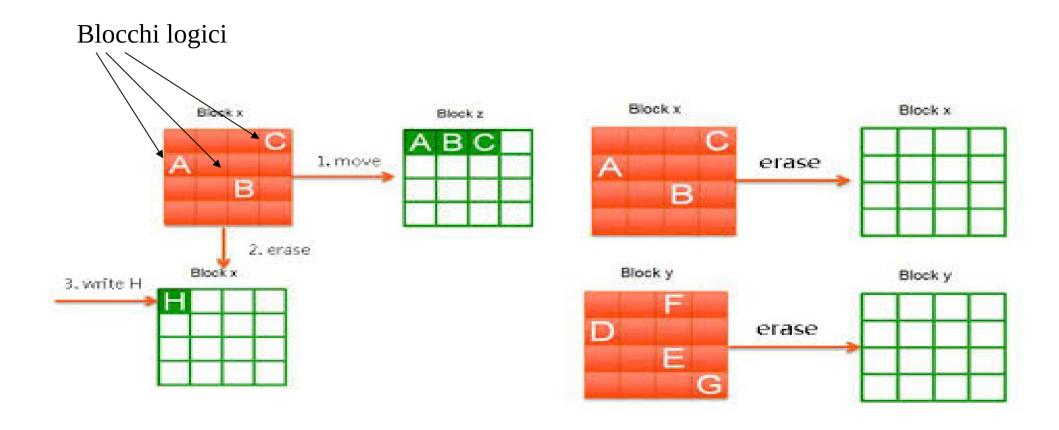
Dettagli

- I blocchi fisici possono contenere più di un blocco logico (detto anche pagina)
- Le scritture portano i blocchi logici ad essere scritti su blocchi fisici cancellati in precedenza (quindi in posizioni differenti del dispositivo)
- La cancellazione viene effettuata tramite algoritmi implementati all'interno del dispositivo (non via software), chiamati garbage collection
- Quando un blocco viene "garbage-collected" i suoi blocchi logici ancora validi vengono riscritti su un nuovo blocco fisico
- Si usa una tecnica detta "over-provisonig" per mantenere almeno una percentuale (ad esempio il 20%) di blocchi fisici liberi per le nuove scrutture e per le riscritture di blocchi logici validi

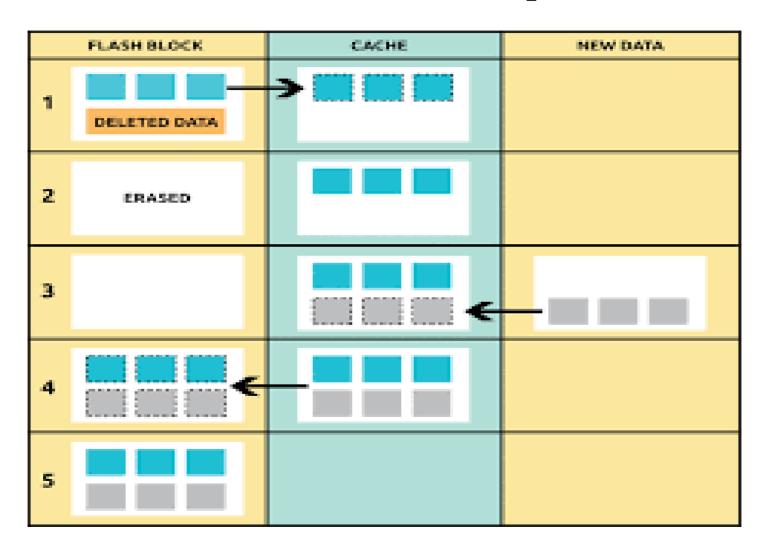
Scheduling SSD e identificazione dei blocchi

- Il sistema operativo tipicamente interagisce con l'SSD secondo regola FIFO
- Viene comunque adottata una sorta di "fusion" delle richieste di scrittura proprio per ottimizzare la durata del dispositivo
- Come detto, su un SSD abbiamo blocchi fisici che contengno più blocchi logici
- Il file system usa i blocchi logici, ed i loro identificatori
- Il mapping di dove si trovi realmente un blocco logico, rispetto al blocco fisico ospitante, è mantenuto da una tabella di lookup interna al dispositivo SSD
- Ogni elemento della tabella è una tupla <blocco-logico, blocco-fisico, pagina> dove blocco-logico è l'identificatore di blocco come usato a livello del file system del sistema operativo

Uno schema basico



Garbace collection e ricompattazione



Semantica della consistenza sul file system

Semantica UNIX

- <u>ogni scrittura</u> di dati sul file system è <u>direttamente visibile</u> ad ogni lettura che sia eseguita successivamente (riletture da buffer cache)
- supportata anche da Windows NT/2000/....
- solo <u>approssimata</u> da NFS (Network File System)

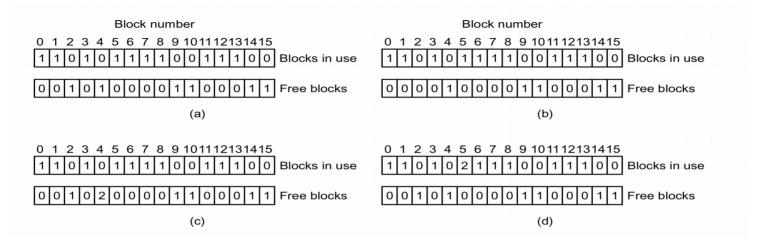
Semantica della sessione

- ogni scrittura di dati sul file system è visibile solo <u>dopo</u> che il file su cui si è scritto è stato chiuso (buffer cache di processo)
- supportata dal sistema operativo AIX (file system ANDREW)

Problematiche di consistenza nei file system

- crash di sistema possono portare il file system in uno stato inconsistente a causa di
- 1. operazioni di I/O ancora pendenti nel buffer cache
- 2. aggiornamenti della struttura del file system ancora non permanenti
- possibilità ricostruire il file system con apposite utility
 - fsck in UNIX
 - scandisk in Windows
- vengono analizzate le strutture del file system (MFT, I-nodes) e si ricava per ogni file system:
 - Blocchi in uso: a quanti e quali file appartengono (si spera uno eccetto che in scenari di deduplicazione)
 - Blocchi liberi: quante volte compaiono nella lista libera (si spera una o nessuna)

Ricostruzione dei file system



- a) Situazione consistente
- **b)** *Il blocco 2 non è in nessun file né nella lista libera*: aggiungilo alla lista libera
- c) Il blocco 4 compare due volte nella lista libera: togli un'occorrenza
- **d)** *Il blocco 5 compare in due file*: duplica il blocco e sostituiscilo in uno dei file (rimedio parziale!!!)

Sincronizzazione del file system UNIX

NAME

fsync, fdatasync - synchronize a file's complete in-core state with that on disk

SYNOPSIS

```
#include <unistd.h>
int fsync(int fd);
int fdatasync(int fd);
```

DESCRIPTION

fsync copies all in-core parts of a file to disk, and waits until the device reports that all parts are on stable storage. It also updates metadata stat information. It does not necessarily ensure that the entry in the directory containing the file has also reached disk. For that an explicit fsync on the file descriptor of the directory is also needed.

fdatasync does the same as fsync but only flushes user data, not the meta data like the mtime or atime.

Sincronizzazione del file system Windows

The FlushFileBuffers function flushes the buffers of a specified file and causes all buffered data to be written to a file.

```
BOOL FlushFileBuffers(
   HANDLE hFile
);
```

Parameters

hFile

[in] A handle to an open file.

The file handle must have the GENERIC_WRITE access right. For more information, see File Security and Access Rights.

If hFile is a handle to a communications device, the function only flushes the transmit buffer.

If *hFile* is a handle to the server end of a named pipe, the function does not return until the client has read all buffered data from the pipe.

stdio.h vs file system API

